PROJETO 02 · ANÁLISE DE VÍDEO

Selfie ao pôr do sol

Storyboard, transcrição, contexto e plano de modelagem.

15,046 segundos · 360 × 662 · 24 fps · 1 composição principal provável



Conclusão visual

O arquivo mantém um homem em enquadramento de selfie diante de uma paisagem rural ao pôr do sol. Há uma composição principal ao longo de todo o vídeo; mudanças de expressão não foram contadas como novas imagens.

Âncora estimada a partir do vídeo final. Origem por IA e imagem original não comprovadas. Transcrição automática, com divergências anotadas; sem revisão auditiva certificadora.

1. Storyboard e âncora principal

A01 · 00:00–00:15,05



Homem adulto de aparência madura, cabelo ondulado castanho e grisalho, barba curta grisalha, camisa de botões verde-oliva/castanha com bolsos e mangas curtas. Rosto e tronco em primeiro plano; braço no lado esquerdo da imagem estendido em direção à câmera, sugerindo selfie. Ao fundo: casa de pedra com telhado de telhas, vegetação, árvores altas estreitas, colinas, céu dourado e sol baixo à esquerda.

Confiança alta na composição contínua; média na hipótese de uma imagem-base. Não é contagem comprovada de arquivos originais.

Apoios da mesma composição



01,505s



07,523s



13,541s

Nas amostras mudam abertura da boca, posição da cabeça, sobrancelhas, olhos e sorriso. O enquadramento e o fundo permanecem muito semelhantes. A leitura é de um plano frontal de fala para câmera, com pequenas oscilações. Não há evidência visual suficiente para dizer se houve uma única geração ou junções de clipes semelhantes.

2. Contexto e direção visual

O que o vídeo mostra

Uma figura masculina se dirige à pessoa que assiste como se tivesse visto sua foto. Faz uma observação afetiva e convida a pessoa a clicar junto à foto do perfil e escutar um áudio. O vídeo mostra somente o apresentador: a foto da destinatária, a interface do perfil e o áudio mencionado não aparecem. As afirmações pertencem ao roteiro; não foram verificadas como acontecimentos reais.

Leitura narrativa

A estrutura sugere aproximação afetiva: atenção individual aparente → elogio emocional → convite de baixa pressão → ação no perfil → reforço pessoal. A ausência de outros personagens mantém o foco na relação entre apresentador e espectador. A referência a “ela” sugere destinatária feminina no texto; não permite concluir idade, público real, relacionamento ou intenção comercial.

Composição e luz

A casa fica à direita, o sol baixo à esquerda e o rosto centralizado. A paleta combina céu dourado, vegetação verde e camisa escura. O cenário evoca ambiente rural mediterrâneo, sem confirmar país ou residência.

Câmera e movimento

Nas amostras mudam abertura da boca, posição da cabeça, sobrancelhas, olhos e sorriso. O enquadramento e o fundo permanecem muito semelhantes. A leitura é de um plano frontal de fala para câmera, com pequenas oscilações. Não há evidência visual suficiente para dizer se houve uma única geração ou junções de clipes semelhantes.

Texto e som

Nenhum texto, legenda ou interface foi observado. A fala foi reconhecida em português; não houve classificação por escuta de timbre, trilha, efeitos ou sincronização labial exata.

Fatos e hipóteses

Uma composição contínua é observável nas amostras. Uso de IA, número de gerações, identidade, localização, origem da voz e imagem inicial são hipóteses ou informações indisponíveis. A foto da destinatária e o áudio citado não são mostrados.

3. Mapa de ritmo e transcrição

As fases abaixo pertencem ao mesmo plano A01. Não representam cortes. Tempos aproximados obtidos por reconhecimento de fala.

Tempo	Função	Conteúdo
00:00.76–00:04.18	Abordagem pessoal	Afirma estar olhando uma foto e decide falar com a pessoa.
00:04.36–00:08.24	Vínculo emocional	Atribui à pessoa uma sensação de paz e algo que não sentia há tempo.
00:08.94–00:11.58	Convite e ação	Condiciona o convite à vontade da pessoa e pede clique na “cruz” da foto.
00:11.72–00:13.00	Próximo conteúdo	Pede que a pessoa escute um áudio que teria deixado.
00:13.38–00:14.68	Fechamento pessoal	Diz querer que seja aquela pessoa ouvindo.

Transcrição com tempos

Transcrição automática comparada entre Whisper medium e small; sem revisão auditiva humana. Tempos aproximados. Divergências marcadas; exatidão literal não certificada.

00:00.76–00:02.40 · Oi, eu fiquei olhando [incerto: a] sua foto aqui.

00:02.52–00:04.18 · Aí pensei: [incerto: ah,] vou falar com ela.

00:04.36–00:06.04 · Porque, sei lá, você me passou uma paz.

00:06.56–00:08.24 · Faz tempo que eu não sentia isso quando vi alguém.

00:08.94–00:10.22 · Se você sentir vontade também,

00:10.46–00:11.58 · clica na cruz da minha foto,

00:11.72–00:13.00 · depois [incerto: escuta o áudio / escuto áudio] que eu deixei.

00:13.38–00:14.68 · Queria muito que fosse você ouvindo.

Colchetes são notas editoriais. A presença de “a”, a interjeição “ah” e a segmentação “escuta o / escuto” exigem conferência auditiva. “Cruz” foi mantido conforme os dois modelos; o botão não aparece no vídeo.

4. Prompts novos para modelar

Os prompts abaixo são reconstruções propostas a partir do quadro observado. Não são os prompts originais. O personagem sugerido é fictício; a identidade da pessoa no vídeo não foi determinada.

Imagem-base

Retrato vertical fotorealista de um personagem adulto fictício, homem de aparência madura, cabelo ondulado com fios grisalhos, barba curta grisalha, camisa verde-oliva de botões com bolsos e mangas curtas, enquadramento de selfie do tronco para cima, um braço estendido em direção à câmera, olhar para a lente e sorriso discreto. Casa rural de pedra com telhas no lado direito, árvores altas estreitas, jardim verde e colinas ao fundo, pôr do sol dourado no alto esquerdo, luz quente com brilho de contorno no cabelo, detalhes naturais de pele, profundidade de campo moderada. Manter composição vertical próxima à referência; sem texto e sem interface de aplicativo.

Animação

Partir da imagem-base A01 como referência de composição. Manter o mesmo personagem, camisa, braço em primeiro plano, posição do sol, casa e árvores. Criar um plano contínuo de aproximadamente 15 segundos de fala para a lente, com movimentos leves de cabeça, piscadas naturais, sorriso discreto e articulação de boca coerente com a fala em português revisada. Câmera em posição de selfie quase fixa, pequenas oscilações apenas. Sem cortes, sem trocar o cenário, sem deformar o rosto ou os dedos. Se a ferramenta não suportar a duração, usar extensões compatíveis e conferir a continuidade.

Esqueleto do roteiro

Saudação pessoal → justificativa para o contato → sensação emocional → convite condicionado à vontade da pessoa → ação no perfil/áudio → fechamento pessoal. Use essa estrutura para escrever uma mensagem nova; não confunda adaptação com transcrição literal.

O que evitar na continuidade

Troca de camisa ou rosto; desaparecimento do braço; deformação de dedos, barba ou dentes; árvore ou telhado mudando de posição; movimento exagerado de câmera; expressão repetindo mecanicamente; fala e boca fora de sincronia.

5. Plano de produção e limitações

1. Preparar uma imagem-base A01, preservando a composição de selfie. O quadro extraído tem 360 × 662; não é uma imagem original de alta resolução.

2. Revisar o áudio e corrigir os trechos incertos antes de gravar ou sintetizar a fala. As duas saídas de ASR estão preservadas no pacote.

3. Animar como um plano único ou usar extensões compatíveis. A duração suportada varia por ferramenta; não se pode inferir a quantidade de gerações do autor.

4. Fazer sincronização labial com a fala revisada e verificar rosto, olhos, barba, camisa, braço e fundo no início, meio e fim.

5. Manter a estrutura de aproximação, vínculo emocional e convite. Se mudar a fala, identificar o resultado como roteiro adaptado.

6. Exportar na proporção original ou recortar deliberadamente. O arquivo não tem proporção exatamente 9:16; ampliar a resolução não recupera detalhe original.

Validação realizada

Leitura técnica com ffprobe; detecção de cortes pelo FFmpeg com limiar 0,08; revisão de 30 amostras a cada 0,5s, três quadros de cena e quadros inicial/final; transcrição com Whisper medium e comparação com small. A revisão não é quadro a quadro integral e não incluiu escuta certificadora.

Limites da análise

Não foi recuperada a imagem de geração. O uso de IA, a identidade, a localização, a origem da voz e a publicação original não foram confirmados. A foto da destinatária e o áudio citado não estão no arquivo. A precisão literal da transcrição continua pendente de escuta.

Organização dos arquivos

Projeto separado da análise anterior. O pacote inclui relatório, mapa JSON, transcrição TXT/SRT, saídas brutas dos modelos, A01 e quadros de apoio. O vídeo enviado não é republicado. Modelos, caches e credenciais não fazem parte da entrega.

6. Evidências visuais · prancha 1/2



Amostras espaçadas em meio segundo. São estados de expressão do mesmo plano; não são imagens âncora diferentes. Os tempos indicam os centros da amostragem por fps=2.

6. Evidências visuais · prancha 2/2



Amostras espaçadas em meio segundo. São estados de expressão do mesmo plano; não são imagens âncora diferentes. Os tempos indicam os centros da amostragem por fps=2.

Apêndice · README.md

README.md

TikTok Storyboard

Skill em português para análise assistida de vídeos de IA: [instruções](skills/tiktok-storyboard/SKILL.md).

Requisitos: Python 3.12, ffmpeg e ffprobe.

```sh python -m venv .venv .venv/bin/pip install -r requirements.txt .venv/bin/python skills/tiktok-storyboard/scripts/analyze.py 'https://www.tiktok.com/@autor/video/ID' --output /tmp/tiktok-analise --transcribe ```

Também aceita um arquivo local. Saídas: metadados, candidatos a cenas com três quadros por cena, pranchas JPEG e transcrição automática opcional. A skill orienta a revisão e produção do relatório final: cenas detectadas não equivalem a imagens originais recuperadas. Transcrição requer baixar um modelo Whisper; uma saída automática não garante exatidão.

TikTok pode bloquear downloads. Nesse caso, use um arquivo fornecido pelo usuário. Nenhum token é necessário para análise local. Não há serviço web para iniciar.
```

Apêndice · SKILL.md

skills/tiktok-storyboard/SKILL.md

--- name: tiktok-storyboard description: Analisa um link público do TikTok ou vídeo enviado; entrega storyboard com imagens âncora prováveis, transcrição com tempos e mapa narrativo para estudo e modelagem. ---

TikTok para storyboard

Responda em português. Ao receber um link, execute a análise; não pare em explicar como fazê-la. Use o checkout existente em /workspace/tiktok; cada tarefa já é isolada, não crie worktrees.

Preparação e obtenção

Use /workspace/tiktok/.venv/bin/python e ffmpeg/ffprobe. O script é skills/tiktok-storyboard/scripts/analyze.py. Crie uma pasta nova por execução, fora de arquivos fonte, por exemplo /tmp/tiktok-<identificador>. Nunca sobrescreva análises anteriores.

Execute com argumentos separados, sem interpolar URLs em comandos de shell:

```text /workspace/tiktok/.venv/bin/python skills/tiktok-storyboard/scripts/analyze.py URL --output /tmp/tiktok-ID --transcribe ```

Não force idioma se não souber qual é. O ASR padrão usa faster-whisper small em CPU; baixa o modelo na primeira execução. Se indisponível, use uma ferramenta de transcrição disponível ou relate o impedimento. Nunca invente transcrição.

Use somente acesso autorizado. Se TikTok exigir login, bloquear o download ou o vídeo estiver privado/removido, relate o erro e peça o arquivo de vídeo. Não contorne controles nem solicite cookies ou credenciais em chat. Não trate descrição/legendas do autor como transcrição verificada.

Revisão obrigatória

1. Leia analysis.json e abra todas as páginas storyboard-*.jpg com a ferramenta de imagens. Revise os quadros early, middle e late de cada cena; extraia quadros adicionais em transições ambíguas com ffmpeg. 2. Os cortes automáticos são candidatos. Movimento de câmera, flashes, morphing e transições podem dividir uma mesma imagem ou esconder mudanças. Agrupe cenas que parecem derivar da mesma composição, preserve recorrências e diferencie quantidade de segmentos e quantidade estimada de âncoras distintas. Não afirme que recuperou os arquivos originais, prompts reais ou ferramenta de geração. 3. Escolha um quadro representativo por âncora provável, mantenha o tempo exato do quadro e indique confiança alta/média/baixa com justificativa. Quando necessário, dê uma faixa estimada da quantidade. Não apresente amostras extraídas como imagens originais. 4. Confira o áudio com capacidade de escuta disponível. A transcrição automática é um rascunho: preserve idioma, palavras, repetições, palavrões e tempos; marque [inaudível] e [incerto: ...]. Não prometa exatidão se não houve revisão auditiva. Separe fala, música, efeitos e texto na tela. Transcreva texto visível por inspeção visual, sem preencher trechos ocultos. 5. Descreva contexto observado (personagens sem identificação especulativa, cenário, ações, estética, iluminação, enquadramento, movimentos, transições,
```

ritmo, gancho, desenvolvimento e encerramento). Separe fatos, interpretação e hipóteses de produção. Não deduza contexto externo não verificado.

Entrega

Crie relatorio.md, storyboard com uma miniatura selecionada por âncora provável, e um mapa estruturado mapa.json. Inclua:

- Fonte, duração, metadados disponíveis e limitações de acesso/revisão. - Contagem de segmentos e estimativa de âncoras distintas, com confiança e ambiguidades. - Tabela cronológica: segmento, início/fim, âncora provável, link do quadro, composição/ação, animação/câmera, texto visível, fala/sons, confiança. - Transcrição literal com timestamps e status da revisão; separe tradução/resumo. - Contexto narrativo e mapa de ritmo, áudio e transições. - Orientações para modelar a estrutura; prompts sugeridos para imagem e animação apenas como reconstruções propostas, nunca como prompts originais recuperados.

O mapa.json deve registrar fonte, duração, segmentos, âncoras prováveis e seus quadros/tempos, confiança, ambiguidades, transcrição e status da revisão. Forneça links reais para os arquivos gerados. Nunca entregue contagens, observações ou fala sem ter examinado as evidências. Se alguma etapa estiver bloqueada, entregue as demais e diga precisamente o que falta.

Apêndice · analyze.py

skills/tiktok-storyboard/scripts/analyze.py

```
001 #!/usr/bin/env python3
002 """Extract evidence for agent-reviewed TikTok storyboards; never infer original assets."""
003 import argparse
004 import json
005 import os
006 from pathlib import Path
007 import re
008 import subprocess
009 from urllib.parse import urlparse
010
011
012 def run(args):
013     return subprocess.run(args, check=True, capture_output=True, text=True).stdout
014
015
016 def main():
017     p = argparse.ArgumentParser(description=__doc__)
018     p.add_argument('source', help='Public TikTok URL or local video')
019     p.add_argument('--output', type=Path, required=True, help='New output directory')
020     p.add_argument('--threshold', type=float, default=0.3)
021     p.add_argument('--transcribe', action='store_true')
022     p.add_argument('--model', default='small')
023     p.add_argument('--language', default=None)
024     a = p.parse_args()
025     if not 0 < a.threshold < 1:
026         p.error('threshold must be between 0 and 1')
027     a.output.mkdir(parents=True, exist_ok=False)
028     out = a.output.resolve()
029     if a.source.startswith(('https://', 'http://')):
030         u = urlparse(a.source)
031         if u.scheme != 'https' or not (u.hostname == 'tiktok.com' or (u.hostname or
    '').endswith('.tiktok.com')):
032             p.error('Use an HTTPS TikTok URL or a local file')
033         import yt_dlp
034         with yt_dlp.YoutubeDL({'outtmpl': str(out / 'source.%(ext)s'), 'noplaylist': True,
035                                'merge_output_format': 'mp4', 'socket_timeout': 30,
036                                'retries': 2, 'writesubtitles': True, 'writeautomaticsub': True,
037                                'subtitleslangs': ['all']}) as dl:
038             info = dl.extract_info(a.source, download=True)
039             video = Path(dl.prepare_filename(info))
040             if not video.exists():
041                 video = out / 'source.mp4'
042             metadata = {k: info.get(k) for k in ('id', 'title', 'description', 'uploader',
    'webpage_url', 'duration')}
043     else:
044         video = Path(a.source).resolve(strict=True)
045         metadata = {'local_file': video.name}
046     probe = json.loads(run(['ffprobe', '-v', 'error', '-show_format', '-show_streams', '-of', 'json',
    str(video)]))
047     duration = float(probe['format']['duration'])
048     # Scene transitions nominate boundaries, not the original image-to-video assets.
049     detected = subprocess.run(['ffmpeg', '-hide_banner', '-i', str(video), '-an', '-vf',
050                                f"select='gt(scene,{a.threshold})',showinfo", '-f', 'null', '-'],
051                                capture_output=True, text=True, check=True)
052     cuts = sorted(set(float(t) for t in re.findall(r'pts_time:([0-9.]+)', detected.stderr)))
053     boundaries = [0.0] + [t for t in cuts if 0.1 < t < duration - 0.1] + [duration]
054     frames = out / 'frames'
055     frames.mkdir()
056     scenes = []
057     from PIL import Image, ImageOps, ImageDraw
058     tiles = []
059     for i, (start, end) in enumerate(zip(boundaries, boundaries[1:]), 1):
060         samples = []
061         for label, fraction in [('early', .1), ('middle', .5), ('late', .9)]:
062             t = start + (end-start)*fraction
```

```
            target = frames / f'{i:03d}-{label}.jpg'
            run(['ffmpeg', '-v', 'error', '-ss', str(t), '-i', str(video), '-frames:v', '1', '-q:v',
    '2', str(target)])
            samples.append({'time': round(t, 3), 'file': str(target.relative_to(out))})
        scenes.append({'scene': i, 'start': start, 'end': end, 'samples': samples, 'anchor_status':
    'candidate_requires_visual_review'})
        with Image.open(out / samples[1]['file']) as im:
            tile = Image.new('RGB', (240, 280), 'white')
            thumb = ImageOps.contain(im.convert('RGB'), (240, 250))
            tile.paste(thumb, ((240-thumb.width)//2, 0))
            ImageDraw.Draw(tile).text((5, 255), f'{i:03d} | {start:.2f}-{end:.2f}s', fill='black')
            tiles.append(tile)
    for page in range(0, len(tiles), 24):
        batch = tiles[page:page+24]
        sheet = Image.new('RGB', (240*4, 280*((len(batch)+3)//4)), '#ddd')
        for j, tile in enumerate(batch):
            sheet.paste(tile, ((j%4)*240, (j//4)*280))
        sheet.save(out / f'storyboard-{page//24+1:02d}.jpg')
    result = {'metadata': metadata, 'duration': duration, 'candidate_scene_count': len(scenes),
              'warning': 'Scene count is not original anchor count. Review samples and transitions
    visually.', 'scenes': scenes}
    (out / 'analysis.json').write_text(json.dumps(result, ensure_ascii=False, indent=2))
    if a.transcribe and any(s['codec_type'] == 'audio' for s in probe['streams']):
        # Cloud homes may be read-only. Set this before importing the model hub.
        os.environ.setdefault('HF_HOME', '/workspace/tiktok/.cache/huggingface')
        from faster_whisper import WhisperModel
        import numpy as np
        # Decode using the installed ffmpeg; avoids PyAV API version mismatches.
        pcm = subprocess.run(['ffmpeg', '-v', 'error', '-i', str(video), '-vn',
                              '-ar', '16000', '-ac', '1', '-f', 's16le', '-'],
                             capture_output=True, check=True).stdout
        audio = np.frombuffer(pcm, dtype=np.int16).astype(np.float32) / 32768
        segments, info = WhisperModel(a.model, device='cpu', compute_type='int8',
    cpu_threads=4).transcribe(audio, language=a.language)
        transcript = [{'start': s.start, 'end': s.end, 'text': s.text} for s in segments]
        (out / 'transcript.json').write_text(json.dumps({'status': 'automatic_unverified', 'language':
    info.language, 'segments': transcript}, ensure_ascii=False, indent=2))
        (out / 'transcript.txt').write_text('\n'.join(f"[{s['start']:.2f}-{s['end']:.2f}] {s['text']}"
    for s in transcript))
    elif a.transcribe:
        (out / 'transcript.txt').write_text('Vídeo sem faixa de áudio.\n')
    print(json.dumps({'output': str(out), 'candidate_scenes': len(scenes)}))


if __name__ == '__main__':
    main()
```

Apêndice · requirements.txt

requirements.txt

```
001 yt-dlp
002 Pillow
003 faster-whisper
```

Apêndice · requirements.lock.txt

requirements.lock.txt

```
anyio==4.15.1
av==19.0.2
click==8.5.0
ctranslate2==4.8.4
faster-whisper==1.2.1
filelock==4.2.4
flatbuffers==25.12.19
fsspec==2026.9.0
h11==0.16.0
hf-xet==1.7.0
httpcore2==2.16.0
httpx2==2.16.0
huggingface_hub==2.3.0
idna==3.20
numpy==2.5.4
onnxruntime==1.31.1
packaging==26.3
pillow==13.0.0
protobuf==7.36.2
PyYAML==6.0.3
tokenizers==0.23.3
tqdm==4.70.1
truststore==0.10.5
typing_extensions==4.16.0
yt-dlp==2026.10.26
```

Apêndice · .gitignore

.gitignore

```
001 .venv/
002 __pycache__/
003 .cache/
004 outputs/
```